


# Design de Sistemas ML



A maioria dos cursos de ML foca apenas nos algoritmos, ignorando os outros componentes essenciais.




# Quem somos nós?



# O Que é Design de Sistemas ML?

O processo de definir a **interface, algoritmos, dados, infraestrutura e hardware** para um sistema de machine learning que satisfaça **requisitos específicos**.



# Requisitos Fundamentais

## Confiabilidade

O sistema deve funcionar corretamente mesmo em condições adversas

## Escalabilidade

Capacidade de lidar com crescimento em volume de dados e tráfego

## Manutenibilidade

Facilidade para atualizar e modificar o sistema ao longo do tempo

## Adaptabilidade

Capacidade de se ajustar a mudanças nos dados e no ambiente

# Perguntas que Este Curso Ajudará a Responder

-  Você treinou um modelo, e agora?
-  Quais são os diferentes componentes de um sistema ML?
-  Como fazer engenharia de dados e features?
-  Como avaliar seus modelos, offline e online?
-  Como monitorar e implantar mudanças continuamente?

# **Este Curso Não Ensinará...**

**Algoritmos de ML/DL**

**Sistemas Computacionais**

**Design UX**



# Machine Learning: Expectativa

Esta classe não ensinará como fazer isso

# Machine Learning: Realidade

Você provavelmente construirá algo como isto (com bugs, mas legal)

# Pré-requisitos

Conhecimento de princípios de programação/estrutura de dados


Entendimento de algoritmos ML

Familiaridade com pelo menos um framework como TensorFlow, PyTorch, JAX

Conhecimentos básicos de teoria da probabilidade

# Valor da IA até 2030

Artificial intelligence (AI) has the potential to create value across sectors.



# 13 trilhões USD

A maior parte estará fora da indústria de internet para consumidores

Precisamos de mais pessoas de áreas não-CS na IA!

# Presencial ou Remoto?

## Aulas


Presenciais

## Horários de Atendimento

Mistura de remoto + presencial

Avise-nos se tiver dúvidas ou preocupações

# Colabore e Participe das Aulas



**WAITING FOR STUDENTS TO TURN VIDEOS ON SO  
I DON'T FEEL LIKE I'M TALKING TO AN EMPTY ROOM**

Agradecemos se você interagir nas aulas

- Mais feedback visual para ajustarmos o material
- Melhor ambiente de aprendizagem
- Melhor noção de quem está na aula

# Avaliação

**30%**

Tarefas

3 tarefas ao longo do curso

**65%**

Projeto Final

Aplicação com ML

**5%**

Participação

Mais informações: <https://unb-sistemas-de-machine-learning.github.io/Disciplina/>

# Projeto Final



## Construir Aplicação

Crie uma aplicação movida por ML



## Trabalho em Grupo

Grupos de três pessoas obrigatório



## Demonstração + Relatório

Formatos criativos encorajados

Procurando colegas para o projeto final?

# Sessão de Projetos

Próxima semana: sessão para discutir ideias de projetos e encontrar potenciais colegas de equipe!



# Código de Honra

Permissivo mas rigoroso - não nos teste ;)

1

OK pesquisar e perguntar publicamente sobre os sistemas.  
Cite todas as fontes.

2

NÃO OK pedir a alguém para fazer tarefas/projetos para você.

3

OK discutir questões com colegas. Divulgue seus parceiros de discussão.

4

NÃO OK copiar soluções de colegas.

# **Equipe do Curso**

Carla Rocha, Isaque Alves e Guilherme



# Trabalho em Andamento



Primeira vez que o curso é oferecido



O assunto é novo, não temos todas as respostas

- Nós também estamos aprendendo!



Agradecemos seu:

- **entusiasmo** para experimentar coisas novas
- **paciência** com coisas que não funcionam perfeitamente
- **feedback** para melhorar o curso

# Recursos

## Site do Curso

 unb-sistemas-de-...



**SistemaML / Optativa – UnB**

– SistemaML / Optativa

## Discussões



Grupo no telegram

## Horários de Atendimento

Começam na próxima semana

Se você se inscreveu sem enviar uma inscrição, envie-nos um e-mail! [caguiar@unb.br](mailto:caguiar@unb.br)

## 2. ML em Pesquisa vs. ML em Produção



# Objetivos Diferentes

## Pesquisa

Desempenho do modelo\*

## Produção

Diferentes stakeholders têm objetivos diferentes

\*Está sendo ativamente trabalhado. Veja "Utility is in the Eye of the User: A Critique of NLP Leaderboards" (Ethayarajh e Jurafsky, EMNLP 2020)

# Objetivos dos Stakeholders

## Equipe ML

Maior precisão



# Diferentes Prioridades

## Equipe ML

Maior precisão



## Vendas

Vende mais anúncios



# Objetivos Conflitantes

## Produto

Inferência mais rápida



## Gestão

Maximiza lucro = demitir equipes ML



# ML Estilo Leaderboard

## Função de utilidade abrangente

- Desempenho do modelo
- Latência
- Custo de predição
- Interpretabilidade
- Robustez

## Adaptável a diferentes casos de uso

Em vez de um ranking para cada conjunto de dados/tarefa, adapta-se às necessidades de cada empresa

## Conjuntos de dados dinâmicos

Mudanças realistas de distribuição com diferentes tipos de alterações

# Latência vs. Throughput



## Latência

Tempo para mover uma folha

## Throughput

Quantas folhas em 1 segundo

# Prioridade Computacional

## Pesquisa

Treinamento rápido, alto throughput

## Produção

Inferência rápida, baixa latência ao gerar previsões

# A Latência Importa

**7%**

## Queda nas conversões

100ms de atraso podem reduzir taxas de conversão em 7% (Estudo Akamai '17)

**0.5%**

## Perda em conversões

30% de aumento na latência custa 0.5% na taxa de conversão (Booking.com '19)

**53%**

## Abandono de página

Usuários abandonam uma página que leva >3s para carregar (Google '16)


# Tempo Real vs. Lote

**Tempo Real**

Baixa latência = alto throughput

**Em Lote (Batch)**

Alta latência, alto throughput



# Dados

## Pesquisa

- Limpos
- Estáticos
- Principalmente dados históricos

## Produção

- Desordenados
- Constantemente mudando
- Históricos + streaming
- Enviesados, e você não sabe o quanto
- Preocupações com privacidade e regulações

# **Conceito de "Time Travel" em ML**

Extremamente difícil garantir a correção ao longo do tempo

# ML em Pesquisa vs. em Produção

## Pesquisa

Dados estáticos

## Produção


Dados constantemente mudando

## Equidade (Fairness)

Bom ter (infelizmente)

Importante

# Problemas de Equidade (Fairness)



## Google Shows Men Ads for Better Jobs

by Krista Bradford | Last updated Dec 1, 2019



between a black box AI surgeon that cannot explain how it works but has a 90% cure rate and a human surgeon with an 80% cure rate. Do you want the AI surgeon to be illegal?

## Interpretabilidade


Pesquisa

Bom ter

Produção

Importante

# Quem Você Escolheria como Cirurgião?




A screenshot of a Twitter post from Geoffrey Hinton (@geoffreyhinton). The tweet contains a thought-provoking question about choosing between AI and human surgeons based on their cure rates.

**Geoffrey Hinton**  
@geoffreyhinton

Suppose you have cancer and you have to choose between a black box AI surgeon that cannot explain how it works but has a 90% cure rate and a human surgeon with an 80% cure rate. Do you want the AI surgeon to be illegal?

12:37 PM · Feb 20, 2020 · Twitter Web App

1.1K Retweets 5.2K Likes



Resultado da pesquisa do Zoom do ano passado

# Resumo: ML em Pesquisa vs. em Produção

## Objetivos

Desempenho do modelo vs. objetivos de diferentes stakeholders

## Prioridade Computacional

Treinamento rápido vs. inferência rápida

## Dados

Estáticos vs. constantemente mudando

## Equidade e Interpretabilidade

Bom ter vs. essencial



### 3. Exercício em Grupo

Cada aula, você será designado aleatoriamente para um grupo

Desta vez: 5 pessoas por grupo

# 8 Minutos - Conhecendo Uns aos Outros

1


## Apresente-se

- De onde você está participando?
- Qual é seu ano/especialização?
- Do que você mais tem medo neste curso?

2

## Projetos Finais

- Está procurando colegas para projetos finais?
- O que você gostaria de fazer no projeto final?
- Alguma preocupação sobre seu projeto final?



## 4. Sistemas ML vs. Software Tradicional

# Software Tradicional

**Separação de Preocupações** é um princípio de design para separar um programa de computador em seções distintas, cada uma abordando uma preocupação separada

- Código e dados são separados
- Entradas no sistema não devem alterar o código subjacente

SEPARATE ALL THE CONCERNS



# Sistemas ML

## Código e Dados Acoplados


Sistemas ML são parte código, parte dados

## Desafio

Não apenas testar e versionar código, mas também testar e versionar dados

A parte difícil!

# Testar e Versionar Dados



## Extremamente Difícil

Garantir a correção ao longo do tempo

## Não Entre em Pânico

Revisitaremos isso mais tarde!

# Versionamento de Dados

 Diffs linha por linha como Git não  
funcionam com conjuntos de  
dados

 Não podemos criar ingenuamente  
múltiplas cópias de grandes  
conjuntos de dados

 Como mesclar alterações?

# Desafios dos Dados

1

Como validar a correção dos dados?

2

Como testar a utilidade das features?

3

Como detectar mudanças na distribuição dos dados?

4

Como saber se as mudanças são ruins para os modelos sem rótulos verdadeiros?


5

Como detectar dados maliciosos?

# Ataques de Envenenamento de Dados

Targeted Backdoor Attacks on Deep Learning Systems Using Data Poisoning (Chen et al., 2017)

# Vulnerabilidades nos Tweets



## SWITCH TRANSFORMERS: SCALING TO TRILLION PARAMETER MODELS WITH SIMPLE AND EFFICIENT SPARSITY

William Fedus\*  
Google Brain  
liamfedus@google.com

Barret Zoph\*  
Google Brain  
barrettzoph@google.com

Noam Shazeer  
Google Brain  
noam@google.com

# Desafios de Engenharia com Grandes Modelos ML

Muito grandes para caber em dispositivos

Consumem muita energia para funcionar em dispositivos

Muito lentos para serem úteis

- Autocompletar é inútil se demorar mais para fazer uma previsão do que para digitar

Se testes unitários/CI levarem horas, os ciclos de desenvolvimento estagnarão



## 5. Mitos da Produção ML

# Mito #1: Implantar é Difícil


## Realidade

Implantar modelos ML está ficando cada vez mais fácil com plataformas modernas

## Desafio Real

O difícil é manter o modelo funcionando bem ao longo do tempo com dados em mudança

# Mito #2: ML é Apenas Sobre Modelos



# Mito #3: Quanto Maior o Modelo, Melhor



## Velocidade

Modelos menores são mais rápidos para inferência



## Custo

Modelos menores usam menos recursos computacionais



## Mobilidade

Modelos menores podem rodar em dispositivos com recursos limitados

# Próximas Aulas

## Aula 2

Modelagem de Dados e Feature  
Engineering

## Aula 3

Treinamento e Avaliação de Modelos

## Aula 4

Implantação e Monitoramento

Visite <https://unb-sistemas-de-machine-learning.github.io/Disciplina/> para notas de aula e materiais adicionais